빅데이터분석기사 필기 — 시험 직전 핵심노트

1과목 — 빅데이터 분석 기획

DIKW 계층

Data → Information → Knowledge → Wisdom

- **Data**: 날것의 숫자/사실 ("기온 35도")
- **Information**: 데이터에 의미 부여 ("오늘 덥다")
- **Knowledge**: 패턴 발견 ("35도 이상이면 아이스크림 판매 증가")
- **Wisdom**: 판단에 적용 ("지금 재고 늘려야겠다")

암묵지 vs 형식지

- **암묵지**: 말로 표현 못하는 지식 (자전거 타는 법, 요리사의 감각)
- **형식지**: 문서화된 지식 (매뉴얼, 레시피)

SECI 모델 (지식 변환 4단계)

단계	변환	예시
공동화(Socialization)	암묵지 → 암묵지	견습생이 장인 옆에서 몸으로 배움
표출화(Externalization)	암묵지 → 형식지	노하우를 매뉴얼/문서로 작성
연결화(Combination)	형식지 → 형식지	문서들을 합쳐 새 문서 생성
내면화(Internalization)	형식지 → 암묵지	매뉴얼 읽고 몸에 체화

데이터베이스 특징 4개

- **통합**: 여러 부서/시스템 데이터를 중복 없이 한 곳에 통합
- **저장**: 물리적 저장
- **공용**: 여러 사용자가 공유
- **변화**: 데이터가 계속 삽입/수정/삭제됨 (정적이지 않음)

기업 DB 시스템 6종

약어	이름	역할
CRM	Customer Relationship Management	고객 관계 관리, 마케팅/영업
SCM	Supply Chain Management	공급망 관리 (원자재→생산→유통)
KMS	Knowledge Management System	사내 지식/노하우 관리
ERP	Enterprise Resource Planning	전사적 자원 관리 (회계/인사/생산 통합)
BI	Business Intelligence	데이터 분석으로 의사결정 지원

약어	이름	역할
BA	Business Analytics	BI보다 한 단계 더 — 예측/처방 분석

빅데이터 특징

- 3V: Volume(양), Velocity(속도), Variety(다양성)
- 5V: 3V + Value(가치), **Veracity(신뢰성/정확성)**
  - **Veracity** = 데이터 **자체의 신뢰성·정확성** (품질 문제 — "이 데이터 믿을 수 있나?")
  - **Value** = 분석을 통해 **가치 있는 통찰을 얻을 수 있는가** ("분석해서 뭔가 얻었나?")
  - 함정: "가치 있는 통찰" → **Value**, "신뢰성" → **Veracity**
- Variety = 정형 / 반정형(JSON, XML, 로그) / 비정형

하둡 / MapReduce

- HDFS: NameNode(메타데이터) + DataNode(실제 데이터)
- MapReduce 흐름: Map → 셔플/소트 → Reduce
  - Map: 키-값 쌍으로 쪼개기
  - 셔플/소트: 같은 키끼리 모으기
  - Reduce: 집계
- Spark: MapReduce 대체, 메모리(RAM) 기반 → 빠름

데이터 수집 도구

- Sqoop: RDB → 하둡, 배치 수집
- Flume: 실시간 로그 스트리밍 수집 (하둡으로 직접)
- Kafka: 생산자 → Kafka → 소비자, 범용 메시지 스트리밍 (중간 버퍼)

NoSQL 종류

DB	방식	예
Redis	키-값 (캐시)	세션 저장
HBase	**분산 컬럼 DB** (분산 파일 시스템 아님!)	대용량 컬럼
Cassandra	컬럼 기반	분산 환경
MongoDB	문서(JSON) 기반	비정형

분석 방법론

CRISP-DM 6단계 (비선형 순환)

1. 비즈니스 이해
2. 데이터 이해
3. **데이터 준비** (전처리, 변수 선택, 파생변수 생성)
4. 모델링
5. 평가
6. 배포

KDD 5단계: 선택 → 전처리 → 변환 → 마이닝 → 해석/평가

SEMMA: 샘플(Sample) → 탐색(Explore) → 수정(Modify) → 모델(Model) → 평가(Assess)

빅데이터 분석방법론 5단계 (CRISP-DM과 다른 별개 개념)

1. 분석 기획
2. 데이터 준비
3. 데이터 분석
4. 시스템 구현
5. 평가 및 전개

분석 마스터 플랜 우선순위: 전략적 중요도 / ROI / 실행 용이성

분석 활용 계획: 모델링 끝나고 세우는 게 아님 → **프로젝트 시작 단계부터** 수립

분석 준비도 6항목 (기업 규모·예산은 없음!)

1. **분석 업무** — 어떤 업무에 분석 적용할지
2. **인력 및 조직** — 분석할 사람·조직
3. **분석 기법** — 어떤 기법 쓸 수 있는지
4. **데이터** — 데이터 보유 여부
5. **분석 문화** — 데이터 기반 의사결정 문화
6. **IT 인프라** — 서버·시스템

> 함정: "기업 규모", "분석 예산", "데이터 품질 등급" → **없음**
> 주의: 데이터 거버넌스(원칙·조직·프로세스)와 혼동 주의 — IT인프라는 거버넌스엔 없고, 준비도엔 있음

ETL

- Extract(추출) → **Transform(변환, 정제)** → Load(적재)
- T = 변환/정제 (운송 아님!)

데이터베이스(DB) 4특성

- **통합**: 여러 부서 데이터를 중복 없이 한 곳에 모음
- **저장**: 물리적 저장매체에 보관
- **공용**: 여러 사용자가 동시에 접근 가능
- **변화**: 데이터가 계속 삽입·수정·삭제됨 (동적, 현재 최신 상태만 유지)

데이터 저장소 (범위 순: DB < 데이터마트 < DW < 데이터 레이크)

	DB	DW	데이터 레이크
데이터 종류	정형	정형 (ETL 거침)	정형+비정형 원시 그대로
상태	현재 최신	정제된 이력	원본 그대로
목적	업무처리(OLTP)	분석(OLAP)	분석 전 보관

- **데이터 웨어하우스(DW)** 4특성: **주제지향성 / 통합성 / 시계열성 / 비휘발성**
    - 주제지향성: 업무 기능이 아닌 분석 주제(고객·판매) 중심

    - 통합성: 여러 소스의 형식·단위를 ETL로 통일해서 합침 (DB 통합과 다름)
    - 시계열성: 시간 축 포함, 과거 이력 보존
    - **비휘발성**: 한번 저장된 데이터는 삭제·수정 안 함 ← DB의 "변화"와 정반대
- **데이터마트**: DW에서 특정 부서용으로 잘라낸 부분집합 (별도 속성 없음)
- **데이터 레이크**: 원시 데이터를 ETL 없이 정형/비정형 모두 그대로 저장 (별도 속성 없음)

> 시험 함정: "DW는 실시간 갱신된다" → **틀림** (비휘발성)
> 시험 함정: "실시간성이 DW 특성이다" → **틀림** (실시간 = OLTP/DB)
> DB vs DW 핵심 대립: DB=**변화** ↔ DW=**비휘발성**

- OLTP: 실시간 트랜잭션 처리 (데이터 쌓기)
- OLAP: 쌓인 데이터 분석 (다차원 분석)

데이터 관리

- 메타데이터: 데이터에 대한 데이터
- MDM (Master Data Management): 핵심 데이터를 **하나의 기준으로 통일**
- 데이터 품질 4속성: **완전성(결측 없음) / 일관성(모순 없음) / 정확성(현실과 일치) / 최신성**
- 데이터 무결성: 데이터가 정확하고 일관성 있게 유지

데이터 거버넌스 3요소 (IT인프라는 구성요소 아님)

- **원칙(Principle)**: 데이터 유지관리 지침/가이드
- **조직(Organization)**: 역할과 책임
- **프로세스(Process)**: 데이터 관리 활동과 체계

데이터 3법 / 비식별화

- 개인정보 보호법, 정보통신망법, 신용정보법
- **가명정보**: 재식별 가능, 동의 없이 연구/통계 목적 사용 가능
- **익명정보**: 재식별 불가, 개인정보보호법 적용 안 됨

비식별화 기술: 가명처리 / 총계처리 / 데이터 범주화 / 데이터 마스킹 / 랜덤라운딩 / 제어라운딩

- **데이터 마스킹**: 수준 높을수록 식별 어려워짐 (쉬워지는 게 아님)

변수의 척도

척도	설명	예
명목	분류만 (순서/크기 없음)	혈액형, 성별
순서(서열)	순서 있음, 간격 불일치	학점(A/B/C), 만족도
등간	간격 동일, 절대 0 없음	온도(섭씨), 점수
비율	절대 0 있음	키, 몸무게, 매출

2과목 — 빅데이터 탐색

결측치 메커니즘 (MCAR / MAR / MNAR)

- **MCAR** (완전 무작위 결측): 결측 원인이 어떤 변수와도 무관. 완전히 랜덤.
- **MAR** (무작위 결측): 결측 원인이 **다른 변수**에 있음. 결측값 자체와는 무관.
    - 예) 남성이 우울증 문항 잘 안 씀 → 원인은 성별(다른 변수)
- **MNAR** (비무작위 결측): **결측값 자체**가 결측의 원인.
    - 예) 연봉 높은 사람이 연봉 안 씀, 혈압 높을수록 혈압 미기록

결측치 처리

- 행 제거 / 평균 대체 / **중앙값** 대체 / 최빈값 대체 / KNN
- **이상치 있을 때 → 중앙값** (평균은 이상치에 민감)
- **범주형 결측치 → 최빈값**
- 회귀분석으로 대체 → 변수 간 관계 보존 (약해지는 게 아님)
- **다중 대치법**: 결측치를 여러 방식으로 다르게 채워 데이터셋 여러 개 생성 → 불확실성 반영
- **Hot-deck 대치**: 비슷한 관측치의 **실제값** 그대로 가져와 대치 (KNN은 평균, Hot-deck은 실제값)

이상치 탐지

- Z-score: $|Z| > 3$ 이면 이상치, $Z = (x - \mu) / \sigma$
- IQR: Q1 - 1.5×IQR 미만 또는 Q3 + 1.5×IQR 초과
    - IQR = Q3 - Q1
    - 범위(max-min)는 이상치에 영향받음, IQR은 영향 안 받음

정규화 vs 표준화

- **정규화(Min-Max)**: 0~1 범위 압축, 이상치 없을 때
- **표준화(Z-score)**: 평균 0, 표준편차 1, 이상치 있을 때
- **Box-Cox 변환**: **양수 데이터에만** 적용, 정규분포에 가깝게 변환

인코딩

방법	특징	언제
원핫(One-hot)	0/1 행렬 (1 0 0 / 0 1 0)	순서 없는 범주형 (혈액형, 색상)
레이블(Label)	그냥 번호 붙이기 (0/1/2)	순서 없는 범주형 (이진 분류)
순서형(Ordinal)	순서 반영해 숫자 할당	순서 있는 범주형 (초<중<고<대)
타겟(Target)	타겟 변수의 평균값으로 대체	고카디널리티 범주형

> 타겟 인코딩 예: 서울 집값 평균 10억 → 서울=10, 부산=5, 대구=3

대표값

- 평균: 이상치에 가장 민감
- 중앙값: 이상치에 덜 민감
- 최빈값: 이상치에 영향 거의 없음, **연속형 데이터에는 부적합**

왜도 (Skewness)

- **왜도 = 0**: 대칭 분포

- **왜도 > 0** (양의 왜도, 오른쪽 꼬리): **최빈값 < 중앙값 < 평균**
- **왜도 < 0** (음의 왜도, 왼쪽 꼬리): 평균 < 중앙값 < 최빈값
- 첨도(Kurtosis): 분포의 뾰족한 정도

공분산행렬 vs 상관행렬

- **공분산**: 단위가 살아있는 상관관계. 단위가 **같을 때** 사용 (예: PCA에서 변수 단위 동일)
- **상관행렬**: 단위 제거하고 -1~1로 표준화. 단위가 **다를 때** 사용
- 변수 단위가 다르면 공분산 수치 자체가 의미없어짐 → 상관행렬로

변동계수 (CV)

- 표준편차 ÷ 평균
- 단위가 **다른** 자료를 비교할 때 사용

상관관계

계수	언제 쓰나
피어슨	등간/비율척도, 선형 관계, 정규분포 가정
스피어만	**서열척도**, 이상치 있거나 비선형일 때 (순위 기반)
포인트-비세리얼	이진변수 ↔ 연속/서열변수
크라메르의 V	범주형 변수 간 상관강도

- 상관계수: -1 ~ 1 (0이면 무관)
- **편상관분석**: 다른 변수 영향 통제 후 두 변수만의 순수 상관관계 측정
- **정준상관분석(CCA)**: **두 변수 집합 간** 상관관계 분석 (예: [키·몸무게] vs [수학·영어점수])

상대위험도(RR) / 승산비(OR)

- **RR (상대위험도)** = 노출군 발생률 / 비노출군 발생률
  - RR=1: 차이 없음 / RR>1: 노출군이 더 위험 / RR<1: 노출군이 보호 효과
  - 예) 흡연자 100명 중 10명 폐암, 비흡연자 100명 중 2명 → RR = 0.1/0.02 = **5**
- **OR (승산비)** = 노출군 odds / 비노출군 odds
  - odds = 발생 확률 / (1-발생 확률)

표본추출 방법

방법	그룹 내부	그룹 간	뽑는 방식	예시
층화추출	**동질** (비슷한 애들)	이질	각 층에서 일부 추출	성별/연령대로 나눠서 각각 추출
군집추출	**이질** (다양한 애들)	동질	집락 몇 개 통째로 추출	학교 몇 개 뽑아서 전수조사

⚠ 층화=층 안 동질, 군집=집락이 모집단 축소판(이질)

표본분산 n-1 이유

- n으로 나누면 모분산보다 **작게** 나옴 (편향 추정량)

- n-1로 나눠야 기댓값 = 모분산 → **불편추정량**
- "계산 편의" / "정규분포 가정" / "중심극한정리" 때문이 아님

점추정 4조건

조건	의미	키워드
불편성	추정량의 기댓값 = 모수 (치우침 없음)	기댓값 = 모수
효율성	불편추정량 중 분산이 가장 작음	분산 최소
일치성	표본 크기 n↑ → 모수에 수렴	n 커질수록
충분성	표본이 모수 추정에 필요한 정보를 최대한 활용	정보 최대 활용

⚠ 헷갈리는 것: **효율 = 분산**, **충분 = 정보**

구간추정 / 신뢰구간

- 점추정(값 하나)보다 범위로 추정하는 게 더 정직함
- **95% 신뢰구간의 정확한 의미**: 같은 방법으로 구간을 100번 만들면 95번은 모수를 포함한다
  - ❌ 틀린 표현: "모수가 이 구간 안에 있을 확률이 95%다" (모수는 고정값, 확률 없음)
- 신뢰수준 높이면 (95%→99%) → 구간 **넓어짐**
- 샘플 크기 n 키우면 → 구간 **좁아짐** (표준오차 $\sigma/\sqrt{n}$ 감소)

가설검정

- **귀무가설(H0)**: 차이/효과 없다
- **대립가설(H1)**: 차이/효과 있다
- **p-value**: 귀무가설이 참일 때 이 결과가 나올 확률
  - $p < 0.05$ → 귀무가설 기각 → 유의미한 차이 있음
  - $p \geq 0.05$ → 귀무가설 기각 못 함
- 유의수준은 상황에 따라 90%, 95%, 99% 등 다양하게 선택 가능 (항상 95% 아님)

오류 구분

	H0 사실	**H0 사실 아님**
H0 채택	옳은 결정	**2종 오류**
H0 기각	**1종 오류**	옳은 결정

- **1종 오류(α)**: H0이 참인데 기각 → 효과 없는데 있다고 판단
- **2종 오류(β)**: H0이 거짓인데 채택 → 효과 있는데 없다고 판단
- **검정력(Power = 1-β)**: H0이 거짓일 때 **올바르게 기각**할 확률 → 높을수록 좋은 검정

> **4칸 표 통째로 암기**:
>
> | | **H0 참** | **H0 거짓** |
> |---|---|---|
> | 기각 | 1종오류(α) | **검정력(1-β)** |

> | | H0 참 | H0 거짓 |
| --- | --- | --- |
| 채택 | 1-α | 2종오류(β) |

검정 종류

- **t검정**: 2집단 평균 차이. t = 평균차이 / 표준오차. 퍼짐 작은데 평균 차이 크면 → 진짜 차이
- **ANOVA(F검정)**: 3집단 이상 평균 차이. F = 집단 간 분산 / 집단 내 분산. t검정을 여러 번 하면 오류 누적되니까 한 번에 검정
- MANOVA: 독립변수 1개 이상 + **종속변수 여러 개**

범주형 검정 3종 (모두 카이제곱 검정)

검정	변수 수	상황	예시
적합도	1개	기대 분포와 비교	주사위가 균등하게 나오나?
독립성	2개, 하나의 표본	두 변수 간 관계	성별 ↔ 흡연 여부 관련 있나?
동질성	여러 집단, 각각 표본	집단 간 분포 같나?	서울/부산/포항 지지 정당 분포 같나?

비모수 검정 (정규분포 가정 불가할 때)

상황	모수 검정	비모수 검정
2집단 독립 비교	t검정	**Mann-Whitney U**
같은 집단 전후 비교	대응표본 t검정	**Wilcoxon signed-rank**
3집단 이상 비교	ANOVA	**Kruskal-Wallis**

- 비모수 = 정규분포 가정 없이 **순위(rank)**로 비교
- Mann-Whitney U = Wilcoxon rank-sum (같은 검정, 이름만 두 개)
- 카이제곱 검정: 두 범주형 변수의 독립성
- **적합도 검정**: 데이터가 특정 분포를 따르는지 확인 (카이제곱 대표)
- 비모수 검정(윌콕슨 등): 정규분포 가정 없을 때

중심극한정리

- 표본 크기 **≥ 30**이면 모집단 분포와 관계없이 표본평균이 정규분포에 근사
- "표본 크기와 관계없이"라는 말이 나오면 틀린 것

EDA

- 기초통계/그래프로 확인 가능: 결측치, 이상치, 데이터 분포
- **통계적 유의성은 기초통계로 확인 불가** → 가설검정 필요

파생변수

- 기존 데이터를 기반으로 새로운 인사이트를 얻기 위해 생성
- 수집 시점이 아닌 **데이터의 특성, 관계, 패턴** 반영이 일반적

불균형 데이터

- Accuracy만으로 평가 불가 (정상 95% / 스팸 5%인데 전부 정상 예측해도 95%)
- **SMOTE**: 소수 클래스 **오버샘플링** (언더샘플링 아님)
- 계층별(Stratified) k-fold로 클래스 비율 유지 가능

3과목 — 빅데이터 모델링

지도 vs 비지도 학습

- **지도학습**: 라벨(정답) 있음 → 분류, 회귀
- **비지도학습**: 라벨 없음 → 클러스터링, 차원축소

분류 vs 회귀

- **분류**: 카테고리 출력 (스팸/아님, 신용등급)
- **회귀**: 연속 숫자 출력 (집값, 전기사용량)

선형회귀

- 데이터에 가장 잘 맞는 직선을 찾아 예측
- 오차 기준: MSE 최소화
- 잔차 가정: 평균=0, 등분산, 정규분포
- **잔차 자유도 = n - p** (p=파라미터 수, 절편 포함, 항상 n-1이 아님)

Lasso / Ridge / Elastic Net (과적합 방지 정규화)

방법	정규화	특징
Lasso (L1)	절댓값 합 최소화	일부 계수 → **0으로 만듦** (변수 선택 효과)
Ridge (L2)	제곱합 최소화	계수를 0에 **가깝게** 축소 (0은 안 됨)
Elastic Net	L1 + L2 결합	두 방식의 장점 결합

로지스틱 회귀

- 이름에 '회귀'지만 **분류** 문제 사용
- 출력: 0~1 확률 → 0.5 기준으로 분류
- 활성화 함수: Sigmoid
- **odds** = p/(1-p) : 성공 확률 vs 실패 확률 비율
- **logit** = log(odds) : -∞~+∞ 범위로 변환 → 선형 방정식으로 모델링 가능
- 계수 β: 변수 1 증가 시 odds가 exp(β)배 변함 (선지 소거용)

KNN (K-Nearest Neighbors)

- 새 데이터 → 가장 가까운 K개 이웃 찾기 → 분류(다수결) / 회귀(평균)
- **K 작으면 → 과적합**, K 크면 → 과소적합
- **Lazy learning**: 학습 단계 없음, 데이터 저장해뒀다가 예측 시 거리 계산
- 결측치 대치에도 같은 원리 사용 (비슷한 K개 찾아서 평균)

SVM (Support Vector Machine)

- 마진(Margin)을 최대화하는 결정 경계 찾기
- **서포트 벡터**: 경계선에 가장 가까운 데이터 포인트
- 선형 + 비선형 분류 모두 가능 (커널 함수 사용)
- **초매개변수(C, 커널 매개변수) 최적화 필요** (필요 없다고 하면 틀린 것)

결정트리 (Decision Tree)

- 비모수적 방법 (정규분포 가정 불필요)
- 조건-결과(if-then)식 규칙 발견
- 동질성이 커지는 방향으로 분기
- 단점: 깊을수록 과적합
- 정지규칙: 최대 깊이 / 최소 샘플 수 / 정보이득 최소치

변수선택법

방법	방식
전진선택법	변수 없이 시작 → 유의한 변수 하나씩 **추가**
후진소거법	모든 변수 포함 후 → 유의하지 않은 변수 하나씩 **제거**
단계적 선택법	추가와 제거를 번갈아 반복

앙상블 방법

방법	학습 방식	대표 알고리즘
배깅	병렬 (독립적, 복원추출)	**랜덤포레스트**
부스팅	순차 (오분류에 가중치)	AdaBoost, GBM, **XGBoost**, LightGBM
스태킹	기본 모델 예측 → 메타 학습기 입력 → 최종 예측	-

> **스태킹**: 보팅(단순 평균)과 다름. 2단계 학습. 기본 모델들의 출력을 새 특성으로 써서 메타 모델이 학습.
> **앙상블 함정**: "앙상블이 항상 개별 모델보다 뛰어나다" → **틀림**

- **AdaBoost**: 오분류 데이터에 더 큰 가중치 부여해 순차 학습
- **XGBoost**: GBM보다 **빠름** (병렬처리, 정규화 내장, 결측치 자동처리)
- **LightGBM**: leaf-wise 분기 (기존 level-wise와 다름)
- 배깅은 병렬화 가능, 부스팅은 순차라 병렬화 불가

나이브 베이즈

- 모든 특성이 **서로 독립**이라고 가정
- **사전확률 + 우도 → 사후확률** 계산 (우도를 계산하는 것이지 사후확률 아님)
- 텍스트 분류(스팸 필터)에 자주 사용

k-fold 교차검증

- 데이터를 k개로 나눔 → k-1개 학습, 1개 검정 → k번 반복

- **핵심 장점**: 모든 데이터가 훈련+검증에 **1번씩** 사용 → 데이터 효율적 활용
- **홀드아웃보다 느림** (k번 반복 학습)
- k가 클수록 신뢰도 올라감 (k=10 > k=2)
- 시계열 데이터: **시간 순서 유지** (무작위 섞으면 안 됨) → 과거로 훈련, 미래로 검증

Bootstrap

- **복원추출**: 뽑고 다시 넣고 또 뽑음 → 같은 데이터 중복 가능
- 데이터가 적을 때 있는 데이터 재활용해서 샘플 여러 개 생성
- **0.632 Bootstrap**: 복원추출 시 원본의 약 63.2%만 뽑힘 → 나머지 36.8%를 테스트셋으로 사용

클러스터링 (비지도학습)

K-Means

- K개 중심점 랜덤 설정 → 가까운 것끼리 묶음 → 중심 재계산 → 반복
- 단점: K 미리 정해야 함, 초기값 민감, 원형 모양만 잘 잡음
- 최적 K 탐색: **엘보우 메소드(Elbow Method)** — 집단 내 제곱합 꺾이는 지점

DBSCAN

- 밀도 기반 클러스터링
- K 미리 안 정해도 됨, 복잡한 모양도 잡음

계층적 군집분석 (Hierarchical)

- K 미리 안 정해도 됨
- 결과: **덴드로그램** (트리 구조)으로 표현, 사용자가 잘라서 군집 수 결정

시계열 분석

정상성 (Stationarity)

- 정상 시계열: **평균/분산이 시간과 무관하게 일정**
- 비정상: 추세(trend)나 분산 변화가 있음
- 계절 패턴도 시점마다 평균이 달라지면 **비정상**

차분 (Differencing)

- 오늘값 - 어제값 → 추세 제거, 정상화
- 차분 후 그래프가 **위아래 일정 범위 안에서 진동, 방향성 없음** → 정상화 성공

ADF 검정 (Augmented Dickey-Fuller)

- 귀무가설: **"이 데이터는 비정상이다"**
- **p < 0.05 → 귀무가설 기각 → 정상** ← 직관과 반대! 주의
- p ≥ 0.05 → 비정상 → 차분 필요

ARIMA(p, d, q)

- **p** (AR 차수): 과거 실제값 몇 개 참고 → **PACF**로 결정
- **d** (차분 횟수): 정상화까지 차분 횟수

- **q** (MA 차수): 과거 예측 오차 몇 개 참고 → **ACF**로 결정
- 외우기: **P**ACF → **p**, ACF → q

ACF vs PACF

- **ACF** (자기상관함수): 현재 vs 과거 lag별 상관관계. **간접 영향 포함** → MA의 **q** 결정
- **PACF** (편자기상관함수): 중간 lag 영향 제거한 **순수 직접 상관관계** → AR의 **p** 결정
- ACF가 lag k에서 뚝 끊기면 q=k, PACF가 lag k에서 뚝 끊기면 p=k

연관분석

- 지지도(Support): A+B 같이 구매한 비율
- 신뢰도(Confidence): A 산 사람 중 B도 산 비율
- **향상도(Lift)**: 실제 연관성 (1보다 크면 연관 있음)
    - 향상도 = 신뢰도 / P(B)

차원 축소

PCA (주성분 분석)

- 첫 번째 주성분: **가장 큰 분산** 설명
- 이후 주성분: 앞 성분과 직교하면서 차례로 최대 분산 설명
- 주성분들 간 상관관계 없음

SVD (특이값 분해)

- 행렬을 특이벡터(U, V)와 특이값(Σ)으로 분해
- **정방행렬 아니어도** 적용 가능 (정방행렬만 된다고 하면 틀린 것)
- 차원 축소, 노이즈 제거에 활용

K-medoids

- K-Means와 동일한 구조, 단 중심점을 평균 대신 **실제 데이터 포인트**로 사용
- **이상치에 강함** (K-Means는 이상치에 중심점이 끌림)

GMM (Gaussian Mixture Model)

- 데이터가 여러 정규분포의 혼합이라고 가정
- **확률적 할당**: "클러스터 A에 속할 확률 70%, B 30%" (K-Means는 딱 잘라 할당)

SOM (자기조직화지도)

- 비지도학습
- 고차원 데이터를 저차원(주로 2차원) 그리드에 매핑 (시각화 목적)

딥러닝

- 인공신경망: 입력층 → 은닉층(여러 겹) → 출력층
- 순전파: 입력 넣어서 예측
- 역전파: 오차를 뒤에서 앞으로 전달하며 **편미분**으로 가중치 조정
- 학습률(Learning Rate): 가중치 조정 폭

활성화 함수

- **ReLU**: 0보다 작으면 0, 크면 그대로 (은닉층에서 주로 사용)
- **Sigmoid**: 0~1 출력, 이진 분류 출력층. 로지스틱 회귀. 출력층에서 주로 사용함.
- **Softmax**: 합이 1, 다중 분류 출력층

과적합 방지

- 드롭아웃(Dropout): 학습 중 랜덤으로 노드 꺼버림
- 조기 종료(Early Stopping), 데이터 증강, 층/노드 수 줄이기

NLP 모델 구분

- **BERT**: 양방향, 문장 앞뒤 문맥 모두 고려
- **GPT**: 대용량 텍스트 사전학습 후 fine-tuning
- **Word2Vec**: 단어를 벡터로 변환
- **YOLO**: NLP 아님! 실시간 **객체탐지(이미지)** 알고리즘

Transformer

- 문장 안 각 단어가 다른 단어들과 얼마나 관련 있는지 계산 → **Self-Attention**
- BERT, GPT 둘 다 Transformer 기반
- 구성요소: Self-Attention, Multi-Head Attention, Positional Encoding
- **Forget Gate는 LSTM 구성요소** (Transformer 아님)

Seq2seq

- Transformer 이전 방식. 번역 모델 구조.
- 인코더: 입력 시퀀스 → 컨텍스트 벡터
- 디코더: 컨텍스트 벡터 → 출력 시퀀스

4과목 — 빅데이터 결과 해석

혼동행렬 (Confusion Matrix)

	예측 Positive	예측 Negative
실제 Positive	TP	FN
실제 Negative	FP	TN

- **T/F** = 예측이 맞냐 틀리냐
- **P/N** = 뭐라고 예측했냐

분류 평가지표

- **Accuracy(정확도)** = (TP+TN) / 전체 — 불균형 데이터에 신뢰 못함
- **Recall(재현율/민감도)** = TP / (TP+FN) — 실제 양성 중 잡아낸 비율
- **Precision(정밀도)** = TP / (TP+FP) — 양성 예측 중 진짜 양성 비율
- **F1-Score** = 2 × (Precision × Recall) / (Precision + Recall) — 조화평균
- **Specificity(특이도)** = TN / (TN+FP) — 실제 음성 중 음성 예측 비율

상황별 지표 선택

- 암 진단 (놓치면 안 됨) → **Recall** 중시
- 스팸 필터 (정상 메일 스팸 처리 안 됨) → **Precision** 중시

임계값(Threshold) 트레이드오프

- 임계값 올리면 → 까다롭게 찍음 → **Precision ↑, Recall ↓**
- 임계값 내리면 → 많이 찍음 → **Precision ↓, Recall ↑**

ROC 곡선 & AUC

- **X축: 1-특이도 (FPR)** — "X축=특이도"라고 하면 틀린 것
- **Y축: 민감도/Recall (TPR)**
- AUC = ROC 곡선 아래 면적
  - AUC = 1 → 완벽한 모델
  - AUC = 0.5 → 랜덤 수준 (동전 던지기)
- **왜 쓰냐**: 임계값에 상관없이 모델 자체 성능 비교. 임계값 바꾸면 Precision↑Recall↓ 등 트레이드오프 있으므로.

PR 곡선 (Precision-Recall 곡선)

- X축: Recall(재현율), Y축: Precision(정밀도)
- **불균형 데이터에서 ROC보다 유용** — ROC는 불균형 시 낙관적으로 보일 수 있음
- AUC-PR: 1에 가까울수록 좋음 (0.5가 기준이 아님)

회귀 평가지표

- **MAE**: 오차 절댓값 평균 — 이상치 덜 민감
- **MSE**: 오차 제곱 평균 — 이상치에 가장 민감
- **RMSE**: MSE의 제곱근 — 단위 복원
- **MAPE**: (|실제-예측| / 실제값) × 100% — 퍼센트 오차, 단위 달라도 비교 가능. 실제값 0이면 사용 불가
- **R^2(결정계수)**: 모델이 데이터 변동을 설명하는 비율
  - $R^2 = 1$ → 완벽, $R^2 = 0$ → 평균값만 출력하는 것과 같음
- **Adjusted R^2**: 변수 개수에 패널티. 쓸모없는 변수 추가 시 R^2는 올라가지만 Adjusted R^2는 안 올라감
- **F1 score는 분류 전용** — 회귀 모델(전기사용량 예측 등)에 사용 불가

클러스터링 평가

- **실루엣 점수**: 각 데이터 포인트마다 계산 후 평균
  - a = 같은 클러스터 내 평균 거리, b = 가장 가까운 다른 클러스터까지 평균 거리
  - 범위 **-1~1**, 1에 가까울수록 좋음, -1이면 잘못된 클러스터링

Lift chart / Gain table

- **Lift** = 모델 사용 시 적중률 / 랜덤 적중률
  - 예) 전체 구매율 10%, 모델 상위 타겟 구매율 20% → Lift = 20%/10% = **2**
  - Lift > 1이면 모델이 랜덤보다 나음
- ROC 곡선(FPR vs TPR)과 다름, PR 곡선(Precision vs Recall)과도 다름

카파 계수 (Cohen's Kappa)

- **우연에 의한 일치를 보정**한 분류 성능 지표
- 범위: **-1~1** (0이면 우연 수준, 1이면 완전 일치) — **0~1이 아님!**
- 군집 응집도(실루엣)와 다름, 회귀 설명력(R^2)과 다름

오분류율 (Misclassification Rate)

- **오분류율 = 1 - Accuracy** = (FP+FN) / 전체
- 낮을수록 좋은 모델
- FP/(FP+TN) = FPR(1-특이도) 와 다름

파라미터 vs 하이퍼파라미터

- **파라미터**: 모델이 학습으로 스스로 결정 (선형회귀 계수, 신경망 가중치)
- **하이퍼파라미터**: 사람이 미리 설정 (학습률, KNN의 K, 결정트리 깊이, K-Means의 K)
- **Grid Search**: 하이퍼파라미터 조합을 다 시도해서 최적값 탐색

회귀 진단 지표 (선지 소거용)

- **잔차 분석**: 잔차가 패턴 없이 랜덤한지 확인
- **Q-Q plot**: 데이터가 정규분포 따르는지 시각적 확인
  - 이론적 정규분포 분위수(X축) vs 실제 데이터 분위수(Y축) 점으로 표현
  - 점들이 직선 = 정규분포
  - 오른쪽 위로 굽음 = **양의 왜도**
  - 이상치도 시각적으로 파악 가능
  - **R^2 계산에 사용되지 않음** — 정규성 확인용 (함정 선지 자주 출제)
  - 왼쪽 위로 굽음 = 음의 왜도
  - R^2 계산에 쓰이지 않음 (정규성 확인용)
- **VIF**: 다중공선성 확인 (독립변수끼리 상관 높으면 문제) — **VIF > 10이면 의심**
- **Cook's distance**: 이상치가 회귀모델에 미치는 영향력

박스플롯으로 알 수 없는 것

- **알 수 있음**: Q1, 중앙값(Q2), Q3, IQR, 이상치 존재 여부, 대략적 왜도 방향
- **알 수 없음**: **평균**, **최빈값**, 정확한 표준편차, 분포 형태
- 박스플롯 중간선 = **중앙값** (평균 아님!)

시각화 종류

목적	그래프
연속형 데이터 분포	히스토그램
분포 + 이상치 확인	박스플롯
두 변수 관계	산점도
시계열 추이	선그래프
범주형 데이터 비교	막대그래프, 원형 차트
상관관계 행렬	히트맵

목적	그래프
범주형 비율 + 상호작용	**모자이크 플롯**
여러 변수 동시 비교	**레이더 차트(방사형)**
3변수 표현 (x, y + 크기)	**버블 차트**
여러 변수 특징 한눈에	**비교시각화**

- **히스토그램은 범주형 시각화가 아님** — 연속형 데이터 전용
- 모자이크 플롯 ≠ 히스토그램 안에 히스토그램 (직사각형 크기+색상으로 비율/상호작용)

K-fold 교차검증 vs 홀드아웃

- k-fold: 홀드아웃보다 **느림** (k번 반복 학습)
- k 클수록 신뢰도 높음

자주 틀리는 함정 모음

함정	정답
X축=특이도	X축=**1-특이도(FPR)**
Lasso는 계수를 0에 가깝게만	Lasso는 0으로 **만들어** 변수 선택
XGBoost가 GBM보다 느리다	XGBoost가 **빠름**
계층적 군집은 K 미리 정해야 함	K 미리 **안 정해도 됨**
오른쪽 꼬리: 최빈값 > 평균	오른쪽 꼬리: 최빈값 **<** 중앙값 **<** 평균
YOLO = NLP	YOLO = **객체탐지(이미지)**
ADF p<0.05 → 비정상	p<0.05 → 귀무가설("비정상이다") 기각 → **정상**
MNAR = 다른 변수가 원인	다른 변수 원인 = **MAR**, 결측값 자체가 원인 = **MNAR**
Forget Gate = Transformer	Forget Gate = **LSTM**
잔차 자유도 = n-1	잔차 자유도 = **n-k-1** (k=독립변수 수)
히스토그램 = 범주형 시각화	히스토그램 = **연속형** 전용
SVD = 정방행렬만	SVD = **직사각형 행렬도** 가능
ETL T = 운송	ETL T = **변환/정제**
HBase = 분산 파일 시스템	HBase = **분산 컬럼 DB**
데이터 거버넌스에 IT인프라 포함	IT인프라 **포함 안 됨** (원칙/조직/프로세스)
표본평균은 크기 관계없이 정규분포	표본 크기 **≥ 30**일 때 (중심극한정리)
나이브 베이즈 = 사전확률+사후확률로 우도 계산	사전확률+**우도**로 **사후확률** 계산
F1 score = 회귀 평가 가능	F1 score = **분류 전용**

함정	정답
분석 활용 계획 = 모델링 후 수립	**프로젝트 시작 단계부터** 수립
박스플롯 중간선 = 평균	중간선 = **중앙값**, 평균은 표시 안 됨
Kappa 범위 = 0~1	Kappa 범위 = **-1~1**
오분류율 = FP/(FP+TN)	오분류율 = **1-Accuracy**
앙상블은 항상 개별보다 뛰어남	항상 뛰어나지는 **않음**
DW는 실시간 갱신된다	DW = **비휘발성**, 수정 안 됨
k-fold는 홀드아웃보다 빠름	k-fold가 **더 느림** (k번 반복)
표본분산 n-1 = 계산 편의	n-1 = **불편추정량** 확보
PR 곡선 = 균형 데이터에 유용	PR 곡선 = **불균형 데이터**에 유용
Veracity = 가치 있는 통찰	Veracity = **신뢰성·정확성** / 가치 있는 통찰 = **Value**
검정력 = α (1종오류)	검정력 = **1-β** (H0 거짓일 때 올바르게 기각)
Q-Q plot = R^2 계산에 사용	Q-Q plot = **정규성 확인용**, R^2 계산과 무관
RF 트리 수 많을수록 항상 향상	일정 수 이상이면 효과 **포화** ("항상" 함정)
원핫 인코딩 = 번호 부여	번호 부여(0/1/2/3) = **레이블 인코딩** / 원핫은 0/1 벡터
KDD: 변환 전에 마이닝	KDD: 선택→전처리→**변환**→마이닝→해석/평가
R^2은 독립변수 추가 시 감소	R^2은 **항상 증가하거나 유지** (감소 안 함)